

Predicción de Riesgo Materno

mediante Signos Vitales y Machine Learning

Introducción al Aprendizaje Automático · UNSAM

12/06/2026

Integrantes del Grupo 4

Gino Mariani

gino_mariani@outlook.com

Tomás Martín

martintomasnahuel@gmail.com

Problema y Objetivos

¿Puede un sistema IoT con ML optimizar la detección temprana de riesgo materno en hospitales de bajos recursos?

Dispositivo IoT

Mide signos vitales continuamente

Modelo ML

Clasifica el nivel de riesgo

Alerta al hospital

Prioriza atención de pacientes

Dataset

- Investigadores de universidades ubicadas en Bangladesh
- 1014 pacientes embarazadas · Hospitales de zonas rurales (2018–2020)
- Signos vitales medidos con dispositivos IoT + registros hospitalarios
- Nivel de riesgo asignado por médicos especialistas

Referencias

Ahmed et al. (2020)

IoT Based Risk Level Prediction Model For Maternal Health Care

Ahmed & Kashem (2020)


Review and Analysis of Risk Factor of Maternal Health using IoT

Exploración de Datos

Variables del dataset


Variable	Rango
Age	10 – 70 años
SystolicBP	70 – 160 mmHg
DiastolicBP	49 – 100 mmHg
BS (glucosa)	6 – 19 mmol/L
BodyTemp	98 – 103 °F
HeartRate	60 – 90 bpm

Distribución de variable target




Boxplots según clase:

SystolicBP



BS



Metodología

Union de clases y binarización del target

Distribución del target binario

Clase	Target	Cantidad	Porcentaje
Low/Mid Risk	0	742	73.2%
High Risk	1	272	26.8%

Desbalance 73/27 compensado con `class_weight='balanced'` — sin modificar los datos

Estrategia de evaluación

- Split 80/20 estratificado — mantiene proporción 73/27 en train y test
- Validación cruzada k=5 para medir desempeños — sobre conjunto train
- Test set reservado exclusivamente para la evaluación del modelo final

Métricas elegidas:

Principal

Recall

Minimizar alertas no enviadas

Secundarias

F1-macro

Controlar falsas alarmas

AUC-ROC

Elegir el umbral óptimo del modelo final

Benchmark: Reglas Clínicas

¿Que pasaría si nuestros sistemas de alerta fallaran? ¿Habria manera de que la paciente sin conocimientos médicos pueda advertirse de su situación?

Reglas del modelo simple

SI SystolicBP $\geq$ 140 mmHg $\rightarrow$ HIGH RISK

Umbral OMS de hipertensión gestacional / preeclampsia

SI BS $\geq$ 7.8 mmol/L $\rightarrow$ HIGH RISK


Umbral OMS de diabetes gestacional

En cualquier otro caso $\rightarrow$ LOW/MID RISK

Métricas — evaluado sobre conjunto TEST

Métrica	Valor
Recall (high risk)	0.907
F1-macro	0.776


Matriz de confusión



Modelo 1: Árbol de Decisión

Elegido por su interpretabilidad y capacidad de capturar relaciones no lineales. Entrenado con las 6 features.

Selección de max_depth (Recall train vs. validación CV k=5)




Óptimo: max_depth = 10

Observación: Si bien el recall bajó un poco, también logró mejorar significativamente el rendimiento para la clase mayoritaria

Métricas — Validación Cruzada (k=5) sobre train

Métrica	Árbol	Benchmark
Recall (high risk)	0.899 ± 0.034	0.907
F1-macro	0.912 ± 0.013	0.776
AUC-ROC	0.938 ± 0.013	N/A

Matriz de confusión



Modelo 2: Random Forest

Ensamble de múltiples árboles. Cada árbol usa un subconjunto aleatorio de filas y $\sqrt{6} \approx 2$ features por división — introduce diversidad y reduce overfitting.

Optimización con GridSearchCV (CV k=5, scoring=Recall)


Hiperparámetro	Rango explorado	Óptimo
n_estimators	10 — 100 (pasos de 10)	30
max_depth	1 — 10	6
min_samples_leaf	5, 10, 15, 20	5

Observación: El random forest no mejora demasiado en comparación al árbol, pero vemos que prioriza el recall por sobre el F1

Métricas — Validación Cruzada (k=5) sobre train


Métrica	RF	Árbol
Recall (high risk)	0.908 ± 0.032	0.899 ± 0.034
F1-macro	0.890 ± 0.030	0.912 ± 0.013
AUC-ROC	0.963 ± 0.013	0.938 ± 0.013

Matriz de confusión



Importancia de Features — Random Forest

Importancia (reducción de impureza Gini)



Comentarios

BS es la variable más importante por amplio margen — la diabetes gestacional es el principal factor de riesgo

SystolicBP es la segunda — confirma la relevancia de la hipertensión gestacional y valida la elección del benchmark

Ambas juntas explican la mayoría del poder predictivo — valida retroactivamente la exploración de datos

Sorprendentemente, **la Edad tiene baja importancia** — intuitivamente se esperaría mayor riesgo a una temprana o tardía edad


HeartRate es la variable menos influyente — a pesar de ser un signo vital habitual, no discrimina bien entre niveles de riesgo en este dataset

Comparación de Modelos

Benchmark sobre TEST · Modelos ML sobre Validación Cruzada (k=5)

Modelo	Recall	F1-macro	AUC-ROC
Benchmark (test)	0.907	0.776	N/A
Árbol de Decisión (CV)	0.899 ±0.034	0.912 ±0.013	0.938 ±0.013
Random Forest (CV) ★	0.908 ±0.032	0.890 ±0.030	0.963 ±0.013

Curva ROC – Árbol vs Random Forest



Análisis comparativo

Benchmark: Es sorprendentemente bueno en con las clases positivas habiendo usado solo dos reglas simples, mas no es del todo fiable.


Árbol de decisión: Mejora ampliamente la capacidad discriminativa del modelo Benchmark.

Random forest: Logra obtener el mejor Recall (métrica principal) y una casi perfecta área bajo la curva ROC.

Análisis de Umbral y Evaluación Final

Modelo seleccionado: **Random Forest** — evaluado por primera y única vez sobre el conjunto TEST

Trade-off Recall / FPR según umbral: Random Forest



Criterio del umbral:

Habiéndonos decantado por el random forest por su recall, al observar el grafico notamos que para aumentarlo aun mas debemos permitir muchos falsos positivos. Teniendo en cuenta que el mismo ya es bastante bueno, elegimos el umbral Youden para maximizar el F1.

Resultados finales sobre TEST con umbral óptimo

Métrica	Resultado
Recall	0.907
F1-macro	0.902
AUC-ROC	0.964

Conclusiones y Trabajo Futuro

Conclusiones

- Con reglas simples se puede armar un modelo bastante competente
- Los modelos de Machine Learning valen la pena para ahorrar tiempos e insumos que puedan ser necesarios en otros pacientes
- Faltaron datos importantes sobre el proceso de construcción del dataset para puntualizar el enfoque

Trabajo Futuro

- Explorar ensambles avanzados: XGBoost y AdaBoost
- Incorporar más variables clínicas: semana de gestación, historial de embarazos
- Validar el modelo en otros contextos geográficos más allá de Bangladesh

Agregar ML al sistema IoT no es imprescindible para detectar riesgo, pero sí para reducir la carga operativa del hospital — ese es el valor real del modelo.

Gracias por escuchar!

Preguntas?